

Proposal Pipeline & Eksperimen Baseline

Prediksi Arah Nilai Tukar USD/IDR dari Berita Geopolitik CNBC dengan NLP Klasik

Proyek NLP - Tugas 2 | Kelompok: [isi nama kelompok] | Anggota: [isi nama dan NIM anggota]

1. Formulasi Tugas

Hipotesis proyek adalah bahwa berita geopolitik global membantu memprediksi pergerakan kurs USD. Pada Tugas 2 hipotesis ini dioperasionalkan menjadi tugas klasifikasi biner harian dan diuji dengan pipeline NLP klasik (lexicon dan vektorisasi TF-IDF) tanpa model pre-trained atau transformer.

1.1 Data

Data berasal dari Tugas 1: 41.406 artikel CNBC (1 Sep 2021 - 1 Sep 2026) yang sudah difilter ke topik geopolitik dan makro (delapan kategori kata kunci). Kurs yang dipakai adalah JISDOR Bank Indonesia harian. Setelah penautan tanggal diperoleh 1.201 hari kerja target, dengan rata-rata 34 artikel per hari.

1.2 Definisi target

Unit prediksi adalah hari kerja T . Target $y_T = 1$ jika $\text{kurs}_T > \text{kurs}_{T-1}$ (rupiah melemah terhadap USD), dan $y_T = 0$ jika sebaliknya. Terdapat 13 hari dengan kurs tidak berubah (1,1%) yang digabungkan ke kelas 0 agar deret hari tetap utuh dan fitur lag tidak terputus. Proporsi kelas 1 adalah 55,4% untuk seluruh data (train 56,1%, validasi 51,2%, test 57,3%).

Klasifikasi biner dipilih dibanding regresi level kurs karena (i) kurs bersifat non-stasioner (14.284 menjadi 17.727 IDR/USD) sehingga level mudah diprediksi lewat tren tanpa ada hubungan dengan berita, (ii) hipotesis proyek berbicara tentang arah pergerakan, dan (iii) metrik arah mudah ditafsirkan dan dibandingkan dengan baseline.

1.3 Penautan berita ke target dan pencegahan data leakage

Data tanggal CNBC hanya berisi tanggal (tanpa jam) dan mengikuti waktu AS, sehingga berita bertanggal d baru tercermin di pasar Asia pada hari kerja berikutnya. Aturan yang dipakai: **berita bertanggal d dipasang ke T , yaitu hari kerja pertama yang benar-benar setelah d** . Akibatnya berita Jumat, Sabtu, dan Minggu semuanya dipakai untuk memprediksi Senin, dan berita pada hari libur nasional dipakai untuk hari kerja berikutnya. Label kurs hari yang sama dengan berita (seperti kolom *kurs_direction* pada keluaran Tugas 1) tidak dipakai karena berita dan kurs pada tanggal yang sama dapat saling tumpang tindih waktu.

- **Fitur kurs** untuk hari T hanya memakai data sampai $T-1$ (semua lag dibuat dengan shift).
- **Vocabulary, IDF, dan SVD** dari TF-IDF di-fit hanya pada hari train, lalu diterapkan ke validasi dan test.
- **Split kronologis tanpa shuffle**; hyperparameter dipilih dengan data validasi; data test dipakai satu kali.

1.4 Pembagian data

Split	Periode target	Jumlah hari	P(y=1)
Train (60%)	2 Sep 2021 - 22 Agu 2024	720	0,561
Validasi (20%)	23 Agu 2024 - 28 Agu 2025	240	0,512
Test (20%)	29 Agu 2025 - 1 Sep 2026	241	0,573

Semua model dilatih pada data train. Data validasi dipakai untuk memilih hyperparameter dan data test dipakai satu kali untuk skor akhir. Berkas hasil pembagian ada di *data/train.csv*, *val.csv*, *test.csv* (matriks

fitur harian) dan *data/splits/*_articles.csv* (level artikel).

1.5 Metrik evaluasi

- **Directional Accuracy (DA)**: proporsi arah yang benar; dibandingkan dengan **majority baseline** (kelas mayoritas train) dan **persistence** (arah hari T sama dengan T-1).
- **F1 macro**: rata-rata F1 kelas 0 dan kelas 1. Model yang hanya menebak kelas mayoritas bisa punya DA lumayan tinggi tetapi F1 macro rendah, sehingga kedua metrik dibaca bersama. Kami juga melaporkan porsi hari yang diprediksi kelas 1 untuk melihat model yang hampir selalu menebak satu kelas.
- Dengan 241 hari test, satu standar error DA sekitar 3 poin, sehingga selisih di bawah sekitar 6 poin tidak dapat dibedakan dari kebetulan.

2. Alasan Pemilihan Pendekatan Ekstraksi Fitur NLP

Ketentuan tugas melarang embedding pre-trained dan model berbasis transformer, sehingga seluruh fitur teks dibangun dari lexicon dan vektorisasi klasik. Dua keluarga fitur dipilih karena saling melengkapi: lexicon memberi sinyal *sentimen* berdimensi rendah, sedangkan TF-IDF menangkap *topik dan kosakata* tanpa asumsi kamus.

2.1 Unit teks: judul

Judul tersedia untuk 100% artikel, singkat, dan ditulis editor untuk merangkum kejadian, sehingga dipakai sebagai teks utama. Keypoints (ringkasan editor CNBC) memberi konteks lebih kaya tetapi hanya ada pada 51,6% artikel dan cakupannya berubah antar tahun (sekitar 46% sampai 62%), yang dapat menimbulkan pergeseran distribusi fitur. Karena itu keypoints tidak dipakai untuk model; pada notebook EDA sinyal sentimen judul dan judul+keypoints dibandingkan secara deskriptif. Isi artikel penuh tidak tersedia dalam dataset dan biaya scraping ulang tinggi, dan ekstraksi entitas tidak dilakukan agar pipeline tetap sederhana.

2.2 Lexicon

- **VADER** (compound, pos, neg): dirancang untuk teks pendek, memanfaatkan kapitalisasi dan tanda baca, sehingga cocok untuk judul berita. Kelemahannya adalah kamus umum, bukan finansial.
- **Loughran-McDonald** (proporsi kata negative, positive, uncertainty, litigious): kamus khusus keuangan yang mengoreksi kata yang bermakna berbeda dalam konteks finansial. Dinormalisasi dengan jumlah token agar tidak bias oleh panjang teks. Kategori *uncertainty* relevan karena ketidakpastian geopolitik sering menggerakkan mata uang safe-haven.

2.3 TF-IDF

Satu dokumen per hari target dibentuk dari gabungan teks bersih (lowercase, tanpa stopword, lemmatized) semua artikel hari itu, kemudian di-vektorisasi dengan TF-IDF (unigram + bigram, min_df 5, max_df 0,8, maksimum 5.000 fitur, sublinear tf). TF-IDF dipilih dibanding Bag-of-Words biasa karena meredam kata yang muncul hampir setiap hari. Karena hanya ada 720 hari train, matriks berdimensi 5.000 dikompresi dengan TruncatedSVD menjadi 50 komponen (fit di train) untuk mengurangi overfitting.


2.4 Agregasi harian

Model bekerja per hari, sehingga skor lexicon tiap artikel diagregasi menjadi rata-rata skor VADER compound, proporsi artikel negatif dan positif, serta rata-rata proporsi kata Loughran-McDonald. Rata-rata dan proporsi dipilih agar hari dengan lonjakan jumlah artikel (hingga 403 artikel) tidak mendistorsi model.

2.5 Pemilihan model

Baseline time-series terdiri dari **naive** (majority dan persistence), **ARIMA(1,0,1)** pada return kurs, dan **XGBoost** dengan fitur kurs saja. Model gabungan memakai **XGBoost yang sama** dengan fitur kurs ditambah fitur NLP, sehingga satu-satunya perbedaan antara baseline XGBoost dan model gabungan adalah fitur NLP. XGBoost berbasis pohon dapat menangkap hubungan non-linear, tidak memerlukan standardisasi fitur, dan dibuat dangkal serta teregularisasi karena datanya hanya ratusan hari. Hyperparameter (kedalaman pohon dan jumlah pohon) dipilih dari grid kecil dengan akurasi arah di data validasi.

3. Diagram Arsitektur Pipeline



Gambar 1. Arsitektur pipeline: dari data Tugas 1 hingga evaluasi. Kotak merah muda menandai titik pencegahan data leakage.

Modul (src/)	Fungsi
config.py, dataset.py	Path dan konstanta; penggabungan target, fitur kurs (lag), dan fitur NLP harian
split.py	Definisi target, penautan berita ke hari T , split kronologis
preprocessing.py	Pembersihan teks (versi ringan untuk lexicon, versi bersih untuk TF-IDF)
features.py	VADER, Loughran-McDonald, agregasi harian, TF-IDF + SVD (fit di train)
baseline.py	Majority, persistence, ARIMA
model.py	XGBoost (fitur kurs saja atau kurs + NLP); pemilihan hyperparameter dengan data validasi
evaluate.py, run_experiments.py	Directional Accuracy, F1 macro, confusion matrix; menjalankan semua eksperimen
export_splits.py	Ekspor data/train.csv, val.csv, test.csv dan berkas artikel per split

4. Hasil Eksperimen Baseline Awal

Tabel 1 merangkum hasil eksperimen. Skor akhir dihitung pada data test (241 hari) yang hanya dipakai satu kali. Hasil lengkap ada di *notebook/02_baseline_experiments.ipynb* dan *results/metrics.csv*.

Model	DA val	DA test	F1 macro test	% prediksi kelas 1 (test)
Majority (naive)	0,512	0,573	0,364	100%

Model	DA val	DA test	F1 macro test	% prediksi kelas 1 (test)
Persistence (naive)	0,542	0,531	0,520	58%
ARIMA(1,0,1)	0,542	0,544	0,518	66%
XGBoost: kurs saja (baseline)	0,525	0,519	0,457	76%
XGBoost: kurs + lexicon (gabungan)	0,575	0,539	0,491	73%
XGBoost: kurs + TF-IDF (gabungan)	0,529	0,502	0,479	64%
XGBoost: kurs + lexicon + TF-IDF (gabungan)	0,571	0,485	0,472	59%

Tabel 1. Hasil evaluasi. DA = Directional Accuracy. Majority baseline test = 0,573. '% prediksi kelas 1' adalah porsi prediksi 'rupiah melemah'; nilai mendekati 100% berarti model hampir selalu menebak kelas mayoritas.

4.1 Temuan

- **Baseline:** majority 0,573, persistence 0,531, ARIMA 0,544, dan XGBoost kurs-saja 0,519 (DA test).
- **Model gabungan** (DA test): kurs + lexicon 0,539; kurs + TF-IDF 0,502; kurs + lexicon + TF-IDF 0,485.
- Tidak ada model gabungan yang mengungguli baseline terkuat (majority atau XGBoost kurs-saja) dengan selisih lebih dari sekitar dua standar error (6.4 poin), sehingga belum ada bukti yang jelas bahwa fitur NLP membantu memprediksi arah kurs.
- Model yang hampir selalu menebak satu kelas (Majority (naive)) memiliki DA yang tidak mencerminkan kemampuan prediksi; F1 macro dan porsi prediksi kelas 1 perlu dibaca bersama DA.

4.2 Interpretasi dan keterbatasan

- Ukuran sampel kecil (720 hari train, 241 hari test) membatasi kemampuan mendeteksi efek kecil; proporsi kelas juga bergeser antar split (51% di validasi, 57% di test).
- Tanggal berita tidak memuat jam terbit sehingga penautan harus konservatif (pergeseran satu hari); jam terbit akan memungkinkan penautan yang lebih presisi.
- Dataset hanya berasal dari satu sumber (CNBC, berbahasa Inggris dan berorientasi AS); VADER berbasis kamus umum sehingga kurang peka terhadap istilah finansial.
- Hasil ini adalah baseline awal. Prediksi arah kurs harian sulit, sehingga hasil yang mendekati majority baseline wajar dan menjadi pembandingan untuk Tugas 3.

4.3 Rencana lanjutan (Tugas 3)

Arah perbaikan yang dapat dicoba: agregasi berbasis topik/kejadian (mis. LDA atau NMF) alih-alih rata-rata sentimen, horizon prediksi yang lebih panjang (arah mingguan), dan penambahan variabel eksogen (indeks dolar, suku bunga).