


Assignment 2

Laporan Akuisisi Data & Preprocessing Strategis

Pemrosesan Bahasa Alami KOM | Kelompok Bobi Kopong



Anggota Kelompok:

Dhimas Putra Sulistio | 24/537952/PA/22811

Bobby Rahman Hartonto | 24/539383/PA/22903

Marco Christian | 24/539714/PA/22915

Raditya Nathaniel Nugroho | 24/543188/PA/23069

**PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2026

1. Formulasi Tugas (definisi target dan pilihan metrik)

Hipotesis proyek adalah bahwa berita geopolitik global membantu memprediksi pergerakan kurs USD. Pada Tugas 2 hipotesis ini dioperasionalkan menjadi tugas klasifikasi biner harian dan diuji dengan pipeline NLP klasik (lexicon dan vektorisasi TF-IDF) tanpa model pre-trained atau transformer.

1.1 Data

Data berasal dari Tugas 1: 41.406 artikel CNBC (1 Sep 2021 - 1 Sep 2026) yang sudah difilter ke topik geopolitik dan makro (delapan kategori kata kunci). Kurs yang dipakai adalah JISDOR Bank Indonesia harian. Setelah penautan tanggal diperoleh 1.201 hari kerja target, dengan rata-rata 34 artikel per hari.

1.2 Definisi Target

Unit prediksi adalah hari kerja T . Target $y_T = 1$ jika $\text{kurs}_T > \text{kurs}_{T-1}$ (rupiah melemah terhadap USD), dan $y_T = 0$ jika sebaliknya. Terdapat 13 hari dengan kurs tidak berubah (1,1%) yang digabungkan ke kelas 0 agar deret hari tetap utuh dan fitur lag tidak terputus. Proporsi kelas 1 adalah 55,4% untuk seluruh data (train 56,1%, validasi 51,2%, test 57,3%). Klasifikasi biner dipilih dibanding regresi level kurs karena (i) kurs bersifat non-stasioner (14.284 menjadi 17.727 IDR/USD) sehingga level mudah diprediksi lewat tren tanpa ada hubungan dengan berita, (ii) hipotesis proyek berbicara tentang arah pergerakan, dan (iii) metrik arah mudah ditafsirkan dan dibandingkan dengan baseline.

1.3 Penautan berita ke target dan pencegahan data leakage

Data tanggal CNBC hanya berisi tanggal (tanpa jam) dan mengikuti waktu AS, sehingga berita bertanggal d baru tercermin di pasar Asia pada hari kerja berikutnya. Aturan yang dipakai: berita bertanggal d dipasangkan ke T , yaitu hari kerja pertama yang benar-benar setelah d . Akibatnya berita Jumat, Sabtu, dan Minggu semuanya dipakai untuk memprediksi Senin, dan berita pada hari libur nasional dipakai untuk hari kerja berikutnya. Label kurs hari yang sama dengan berita (seperti kolom `kurs_direction` pada keluaran Tugas 1) tidak dipakai karena berita dan kurs pada tanggal yang sama dapat saling tumpang tindih waktu.

- Fitur kurs untuk hari T hanya memakai data sampai $T-1$ (semua lag dibuat dengan shift).
- Vocabulary, IDF, dan SVD dari TF-IDF di-fit hanya pada hari train, lalu diterapkan ke validasi dan test.
- Split kronologis tanpa shuffle; hyperparameter dipilih dengan data validasi; data test dipakai satu kali.

1.4 Pembagian Data

Kategori	Cakupan & Rasionalisasi	Contoh Keyword	Artikel
<i>Train (60%)</i>	2 Sep 2021 - 22 Agu 2024	720	0,561
<i>Validasi (20%)</i>	23 Agu 2024 - 28 Agu 2025	240	0,512
<i>Test (20%)</i>	29 Agu 2025 - 1 Sep 2026	241	0,573

Semua model dilatih pada data train. Data validasi dipakai untuk memilih hyperparameter dan data test dipakai satu kali untuk skor akhir. Berkas hasil pembagian ada di data/train.csv, val.csv, test.csv (matriks fitur harian) dan data/splits/*_articles.csv (level artikel).

1.5 Metrik Evaluasi

- Directional Accuracy (DA): proporsi arah yang benar; dibandingkan dengan majority baseline (kelas mayoritas train) dan persistence (arah hari T sama dengan T-1).
- F1 macro: rata-rata F1 kelas 0 dan kelas 1. Model yang hanya menebak kelas mayoritas bisa punya DA lumayan tinggi tetapi F1 macro rendah, sehingga kedua metrik dibaca bersama. Kami juga melaporkan porsi hari yang diprediksi kelas 1 untuk melihat model yang hampir selalu menebak satu kelas.
- Dengan 241 hari test, satu standar error DA sekitar 3 poin, sehingga selisih di bawah sekitar 6 poin tidak dapat dibedakan dari kebetulan.

2. Alasan Pemilihan Pendekatan Ekstraksi Fitur NLP

Ketentuan tugas melarang embedding pre-trained dan model berbasis transformer, sehingga seluruh fitur teks dibangun dari lexicon dan vektorisasi klasik. Kami menggunakan dua pendekatan fitur, yaitu lexicon dan TF-IDF karena mereka saling melengkapi. Lexicon memberi sinyal sentimen berdimensi rendah, sedangkan TF-IDF menangkap topik dan kosakata tanpa asumsi kamus.

2.1 Unit teks: judul

Judul tersedia pada seluruh artikel (100%), sehingga judul digunakan sebagai teks utama dalam penelitian ini. Selain itu, judul dibuat oleh editor dan biasanya sudah dirancang untuk merangkum inti dari suatu kejadian, sehingga dianggap cukup representatif untuk digunakan sebagai sumber teks.

Dataset juga menyediakan keypoints, yaitu ringkasan yang dibuat oleh editor CNBC untuk memberikan konteks tambahan. Namun, keypoints hanya tersedia pada 51,6% artikel dan persentasenya juga berbeda-beda di setiap tahun, yaitu sekitar 46% hingga 62%. Kondisi tersebut dikhawatirkan dapat menyebabkan perbedaan distribusi fitur antar tahun. Oleh karena itu, keypoints tidak digunakan sebagai input utama model. Meskipun demikian, pada tahap EDA dilakukan perbandingan secara deskriptif antara sinyal sentimen dari judul saja dengan kombinasi judul dan keypoints.

Sementara itu, isi artikel secara lengkap tidak tersedia di dalam dataset. Pengambilan ulang data (scraping) juga membutuhkan biaya dan proses tambahan, sehingga tidak dilakukan. Ekstraksi entitas juga tidak diterapkan agar pipeline yang digunakan tetap sederhana dan sesuai dengan tujuan penelitian.

2.2 Lexicon

Dalam penelitian ini digunakan dua jenis *lexicon*, yaitu VADER dan Loughran-McDonald.

- VADER digunakan untuk mendapatkan nilai *compound*, *positive*, dan *negative*. VADER dirancang untuk menganalisis teks yang relatif pendek dan mempertimbangkan penggunaan huruf kapital serta tanda baca. Hal ini membuat VADER cukup sesuai untuk digunakan pada judul berita. Namun, VADER menggunakan kamus yang bersifat umum sehingga belum secara khusus mempertimbangkan konteks dalam bidang keuangan.

- Loughran-McDonald digunakan untuk menghitung proporsi kata yang termasuk dalam kategori *negative*, *positive*, *uncertainty*, dan *litigious*. Lexicon ini memang dikembangkan khusus untuk teks keuangan, sehingga dapat membedakan beberapa kata yang memiliki makna berbeda ketika digunakan dalam konteks finansial. Nilai setiap kategori kemudian dinormalisasi berdasarkan jumlah token dalam teks agar hasilnya tidak terlalu dipengaruhi oleh panjang judul. Kategori *uncertainty* juga digunakan karena ketidakpastian, khususnya yang berkaitan dengan kondisi geopolitik, dapat memengaruhi pergerakan mata uang yang dianggap sebagai *safe-haven*.

2.3 TF-IDF

Untuk setiap hari, dibuat satu dokumen target yang berisi gabungan dari seluruh teks artikel pada hari tersebut. Sebelum dilakukan pemrosesan, teks dibersihkan terlebih dahulu dengan mengubah seluruh huruf menjadi lowercase, menghapus stopword, dan melakukan lemmatization. Selanjutnya, teks diubah menjadi fitur numerik menggunakan TF-IDF dengan kombinasi unigram dan bigram. Parameter yang digunakan yaitu `min_df` sebesar 5, `max_df` sebesar 0,8, maksimal 5.000 fitur, serta penggunaan sublinear TF.

TF-IDF dipilih karena dapat mengurangi bobot kata-kata yang terlalu sering muncul di hampir setiap dokumen, sehingga fitur yang dihasilkan diharapkan lebih informatif dibandingkan penggunaan Bag-of-Words biasa. Karena jumlah data training hanya terdiri dari 720 hari, jumlah fitur yang cukup besar tersebut kemudian dikurangi menggunakan TruncatedSVD menjadi 50 komponen. Proses SVD dilakukan dengan fit hanya pada data training untuk mengurangi risiko overfitting dan menjaga agar informasi dari data lain tidak masuk ke proses pelatihan.

2.4 Agregasi harian


Karena model yang digunakan bekerja berdasarkan data harian, skor lexicon dari setiap artikel kemudian digabungkan menjadi fitur pada tingkat harian. Agregasi dilakukan dengan menghitung rata-rata skor VADER compound, proporsi artikel yang memiliki sentimen negatif dan positif, serta rata-rata proporsi kata berdasarkan kategori pada Loughran-McDonald.

Penggunaan nilai rata-rata dan proporsi dilakukan agar jumlah artikel yang berbeda-beda setiap harinya tidak terlalu memengaruhi hasil model. Hal ini penting karena terdapat hari tertentu dengan jumlah artikel yang jauh lebih banyak, bahkan mencapai 403 artikel, sehingga jika menggunakan jumlah mentah, hari dengan artikel lebih banyak dapat memberikan pengaruh yang tidak proporsional terhadap model.

2.5 Pemilihan model

Baseline time-series terdiri dari naive (majority dan persistence), ARIMA(1,0,1) pada return kurs, dan XGBoost dengan fitur kurs saja. Model gabungan memakai XGBoost yang sama dengan fitur kurs ditambah fitur NLP, sehingga satu-satunya perbedaan antara baseline XGBoost dan model gabungan adalah fitur NLP. XGBoost berbasis pohon dapat menangkap hubungan non-linear, tidak memerlukan standardisasi fitur, dan dibuat dangkal serta teregularisasi karena datanya hanya ratusan hari. Hyperparameter (kedalaman pohon dan jumlah pohon) dipilih dari grid kecil dengan akurasi arah di data validasi.

3. Diagram Detail dari Arsitektur Pipeline yang Diajukan



Gambar 1. Arsitektur pipeline: dari data Tugas 1 hingga evaluasi. Kotak merah muda menandai titik pencegahan data leakage.

Modul (src/)	Fungsi
config.py, dataset.py	Path dan konstanta; penggabungan target, fitur kurs (lag), dan fitur NLP harian
split.py	Definisi target, penautan berita ke hari T, split kronologis
preprocessing.py	Pembersihan teks (versi ringan untuk lexicon, versi bersih untuk TF-IDF)
features.py	VADER, Loughran-McDonald, agregasi harian, TF-IDF + SVD (fit di train)
baseline.py	Majority, persistence, ARIMA
model.py	XGBoost (fitur kurs saja atau kurs + NLP); pemilihan hyperparameter dengan data validasi
evaluate.py, run_experiments.py	Directional Accuracy, F1 macro, confusion matrix; menjalankan semua eksperimen
export_splits.py	Ekspor data/train.csv, val.csv, test.csv dan berkas artikel per split

4. Hasil Eksperimen Baseline Awal

Tabel 1 merangkum hasil eksperimen. Skor akhir dihitung pada data test (241 hari) yang hanya dipakai satu kali. Hasil lengkap ada di notebook/02_baseline_experiments.ipynb dan results/metrics.csv.

Model	DA (val)	DA (test)	F1 macro (test)	% prediksi kelas 1 (test)
Majority (naive)	0,512	0,573	0,364	100%
Persistence (naive)	0,542	0,531	0,520	58%
ARIMA (1,0,1)	0,542	0,544	0,518	66%
XGBoost: kurs saja (baseline)	0,525	0,519	0,457	76%
XGBoost: kurs + lexicon (gabungan)	0,575	0,539	0,491	73%
XGBoost: kurs + TF-IDF (gabungan)	0,529	0,502	0,479	64%

XGBoost: kurs + lexicon + TF-IDF (gabungan)	0,571	0,485	0,472	59%
---	-------	-------	-------	-----

4.1 Hasil

- Baseline: majority 0,573, persistence 0,531, ARIMA 0,544, dan XGBoost kurs-saja 0,519 (DA test).
- Model gabungan (DA test): kurs + lexicon 0,539; kurs + TF-IDF 0,502; kurs + lexicon + TF-IDF 0,485.
- Tidak ada model gabungan yang mengungguli baseline terkuat (majority atau XGBoost kurs-saja) dengan selisih lebih dari sekitar dua standar error (6.4 poin), sehingga belum ada bukti yang jelas bahwa fitur NLP membantu memprediksi arah kurs.
- Model yang hampir selalu menebak satu kelas (Majority (naive)) memiliki DA yang tidak mencerminkan kemampuan prediksi; F1 macro dan porsi prediksi kelas 1 perlu dibaca bersama DA.

4.2 Interpretasi dan keterbatasan

- Ukuran sampel kecil (720 hari train, 241 hari test) membatasi kemampuan mendeteksi efek kecil; proporsi kelas juga bergeser antar split (51% di validasi, 57% di test).
- Tanggal berita tidak memuat jam terbit sehingga penautan harus konservatif (pergeseran satu hari); jam terbit akan memungkinkan penautan yang lebih presisi.
- Dataset hanya berasal dari satu sumber (CNBC, berbahasa Inggris dan berorientasi AS); VADER berbasis kamus umum sehingga kurang peka terhadap istilah finansial.
- Hasil ini adalah baseline awal. Prediksi arah kurs harian sulit, sehingga hasil yang mendekati majority baseline wajar dan menjadi pembanding untuk Tugas 3.